Predicción de Riesgo de un Trastorno del Sueño usando Machine Learning

Gabriela Chimali Nava Ramírez | A01710530

19/04/2026

1. DESCRIPCIÓN DEL DATASET

El *dataset* utilizado para este modelo es un archivo cvs que contiene 100,000 registros sintéticos de pacientes para garantizar su privacidad. Sin embargo, sus distribuciones y correlaciones están calibradas con fuentes de investigación clínica de alto nivel, incluyendo la Encuesta Nacional de Entrevistas de Salud del CDC (2024), estudios de la *Sleep Foundation*, *Frontiers in Sleep (2025)* y el *Framingham Heart Study* [1]. Esto asegura que las relaciones estadísticas reflejan patrones del mundo real.

2a.- Estructura de Datos

Para un análisis integral, las variables del estudio se presentaron en seis dimensiones clave: Demográfica (perfil del usuario), Arquitectura del Sueño (métricas físicas del descanso), Estilo de Vida (hábitos y actividad física), Contexto Psicológico (estado mental y niveles de estrés), Factores de Salud (indicadores clínicos) y Factores Ambientales (clima y estacionalidad). Cabe destacar que, aunque el dataset original contaba con 32 columnas, el proceso de preprocesamiento y codificación expandió la cantidad de características a 57 variables, pero optimizó la representación de los datos para el entrenamiento del modelo.

Variable objetivo/dependiente:

Atributo	Descripción	Rango/Ejemplo
sleep_disorder_risk	Multicategoría que clasifica el riesgo de trastornos del sueño	Healthy, Mild, Moderate, Severe

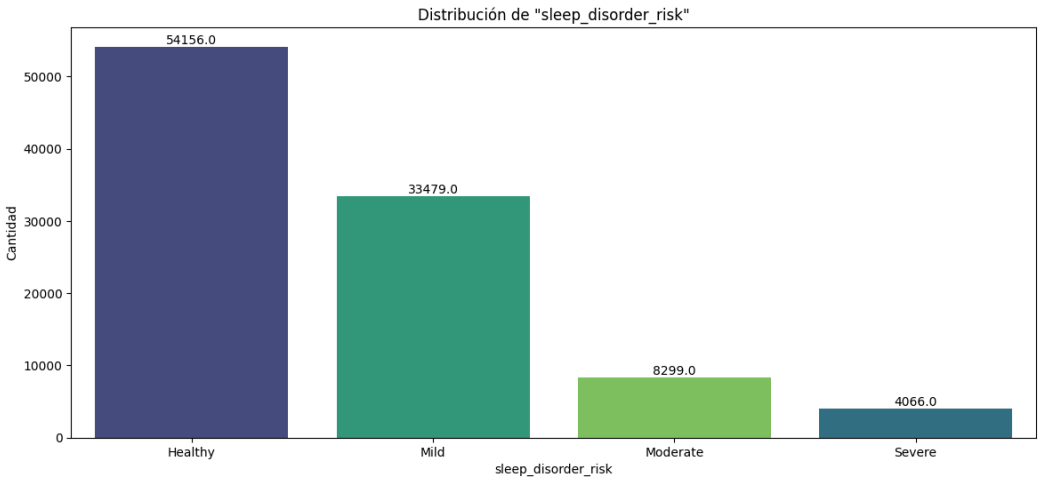

Figura 1. Distribución de la variable objetivo/dependiente.

Variables numéricas:

Atributo	Descripción	Rango/Ejemplo
age	Edad en años	18-69 años
bmi	Índice de Masa Corporal. Medida de la grasa corporal basada en el peso y altura	16-45
sleep_duration_hrs	Duración del sueño en ese día/noche	3-10.5 horas
sleep_quality_score	Clasificación subjetiva de la calidad del sueño	1 = muy mala / 10 = excelente
rem_percentage	Porcentaje de sueño en fase REM	10-30%
deep_sleep_percentage	Porcentaje de sueño en la fase de sueño profundo (ondas lentas)	5-30%
sleep_latency_mins	Tiempo en minutos que se tarda en quedarse dormido, valores >30 indican señal de insomnio	1-58 minutos
wake_episodes_per_night	Cantidad de veces que se despertó durante la noche	0-8 veces

alcohol_units_before_bed	Vasos de alcohol consumidos antes de acostarse	0-6 unidades			
screen_time_before_bed_mins	Tiempo de pantalla en minutos antes de acostarse	2-180 minutos			
steps_that_day	Total de pasos en el día	500-20,000 pasos			
nap_duration_mins	Duración en minutos de las siestas en el día	0-116 minutos			
stress_score	Calificación percibida del estrés ese día	1 = muy bajo / 10 =extremo			
work_hours_that_day	Horas trabajadas ese día (incluye fines de semana)	0-18 horas			
heart_rate_resting_bpm	Frecuencia cardiaca en reposo	45-99 latidos por minuto			
room_temperature_celsius	Temperatura del cuarto en grados Celsius. Rango óptimo entre 18-20°C)	15-28°C			
weekend_sleep_diff_hrs	Diferencia entre la duración del sueño entre fin de semana y días hábiles(jet lag social)	-1-3 horas			
caffeine_mg_before_bed	Cafeína en miligramos consumida mínimo 3 horas antes de acostarse	● 0 ● 40	● 80 ● 100	● 150 ● 200	● 300 ● 400

Variables categóricas nominales:

Atributo	Descripción	Rango/Ejemplo
gender	Identidad de género del paciente	Female, Male, Other
occupation	Ocupación del individuo	Student, Software Engineer, Nurse, Manager, Teacher, Doctor, Retired, Sales, Freelancer, Driver, Homemaker, Lawyer
country	País de residencia del paciente (15 categorías)	● USA ● Germany ● South Korea ● India ● Canada ● Mexico ● Japan ● France ● Netherlands ● UK ● Australia ● Spain ● Brazil ● Italy ● Sweden
chronotype	Preferencia natural del ciclo sueño-vigilia; aquellos tipo vespertino (Evening) suelen tardar más en conciliar el sueño	Neutral (sin preferencia marcada) Morning (duermen y despiertan temprano) Evening (duermen y despiertan tarde)
mental_health_condition	Estado de salud mental existente que afecta los patrones de sueño	Healthy, Anxiety, Depression, Both
season	Estación del año al momento del registro; afecta el ritmo circadiano	Spring, Summer, Autumn, Winter

Variables categóricas binarias:

Atributo	Descripción
exercise_day	El individuo se ejercitó ese día (1 = sí / 0 = no)
sleep_aid_used	Se utilizó un auxiliar para dormir (melatonina, medicación) esa noche (1 = sí / 0 = no)
shift_work	La persona realiza trabajo por turnos rotativos o nocturnos (1 = sí / 0 = no)
day_type	El registro es de un día hábil “Weekday” o fin de semana “Weekend”

2b.- División de Dataset en Conjuntos para Entrenamiento, Validación y Prueba

El conjunto de datos se dividió en subconjuntos de entrenamiento(train), validación(validation) y prueba(test) utilizando la función *train_test_split* de la biblioteca *scikit-learn*. Inicialmente, se separó el **70%** de los datos para entrenamiento y el 30% restante se destinó a un conjunto temporal. Posteriormente, este 30% se dividió equitativamente para obtener los conjuntos de validación y prueba (**15%** cada uno del total).

La partición se realizó de forma estratificada con respecto a la variable objetivo, con el fin de preservar la distribución de clases en cada subconjunto. Además, se usó una semilla aleatoria (*random_state*=42) para garantizar la reproducibilidad de resultados.

2. PREPROCESAMIENTO DE DATOS

3a.- Limpieza Inicial

Se eliminó la variable categórica “patient_id”, aunque fue de utilidad para validar que no existiera el *id* duplicado de un paciente no aporta información relevante para el modelo de predicción.

También, se eliminaron las variables “cognitive_performance_score” y “felt_rested”, ya que, aunque fueron propuestas como variables objetivo en la documentación original del *dataset*, no forman parte del alcance en este estudio.

Asimismo, la variable categórica binaria “day_type” fue transformada en una variable de tipo int mediante una codificación 0/1, asignando el valor de 1 a los días hábiles (Weekday) y 0 a los fines de semana (Weekend), con el fin de facilitar su uso en el modelo.

3b.- Estandarización de variables numéricas

Como parte del preprocesamiento, se aplicó una estandarización tipo z-score a las variables numéricas, transformándolas para tener media cero y desviación estándar uno. Esto permite que las variables sean comparables en escala, evitando que aquellas con mayor magnitud influyan desproporcionadamente en el entrenamiento del modelo. Contribuye a la estabilidad del ajuste.

Para prevenir fuga de información (*data leakage*), los parámetros de estandarización (media y desviación estándar) se calcularon a partir del conjunto de entrenamiento, y posteriormente se aplicaron sin modificación a los conjuntos de validación y prueba. Este procedimiento se implementó utilizando la clase *StandardScaler* de la biblioteca *scikit-learn*, ajustando el modelo sólo con los datos de entrenamiento y reutilizando dichos parámetros en los demás conjuntos.

3c.- Codificación de variables categóricas

Se aplicó codificación *One-Hot Encoding* a las variables categóricas nominales, aquellas sin orden inherente entre categorías. Esta técnica transforma cada categoría en una variable binaria, tomando el valor de 1 cuando el registro pertenece a dicha categoría y 0 en caso contrario. Este enfoque evita introducir relaciones ordinales irreales que podrían surgir al codificar las categorías con números enteros.

Para prevenir problemas de multicolinealidad, se utilizó una codificación de n-1 categorías, omitiendo una como referencia. Esto elimina la dependencia lineal entre las variables generadas (que su suma sea 1), y así el modelo estima los efectos de cada categoría en relación con la categoría base.

Finalmente, para la variable objetivo se aplicó una codificación *Label Encoder* transformando las 4 clases a valores numéricos enteros secuenciales, interpretables por un modelo matemático.

3d.- Consideraciones Adicionales

Finalmente, el dataset original contaba con 32 columnas. Tras el proceso de limpieza y transformación, la estructura final se ajustó de la siguiente manera.

Estado del *dataset*	**Número de columnas**	**Acción**
Original	32	Carga inicial del CSV.
Post-Limpieza	29	Eliminación de IDs y targets secundarios.
Preprocesamiento Final	58	Aplicación de estandarización y codificación.

3. MODELO BASE

Capa (Tipo)	**Configuración**	**Justificación**
Densa	128 neuronas, activación ReLU	Capacidad suficiente para extracción inicial de parámetros .
Regularización	Batch Normalization	Estabiliza el aprendizaje y acelera la convergencia.
Dropout	Tasa de 0.3	Evitar el sobreajuste y promover la generalización.
Densa_1	64 neuronas, activación ReLU	Refinamiento de los parámetros.

Dropout_1	Tasa de 0.2	Evitar el sobreajuste.
Densa_2	4 neuronas, activación Softmax	Genera la distribución de probabilidad de las 4 clases.

4. EVALUACIÓN DE RESULTADOS

4a.- Estabilidad y Convergencia

Gráficas y evaluación de Accuracy y Loss a través de los conjuntos

4b.- Desempeño por Clase

Matriz de Correlación

F1- Score

Precision

Recall

5. REFERENCIAS

[1] Krishna, M.(2026, 12 abril). *Sleep Health & Daily Performance Dataset*. Kaggle. https://www.kaggle.com/datasets/mohankrishnathalla/sleep-health-and-daily-performance-dataset/data

[2]