Predicción de Riesgo de un Trastorno del Sueño usando Machine Learning

Gabriela Chimali Nava Ramírez | A01710530

19/04/2026

ABSTRACT *Este estudio presenta el desarrollo y evaluación de un modelo de Aprendizaje Profundo (Deep Learning) diseñado para la clasificación multiclase del riesgo de trastornos del sueño. Utilizando un conjunto de datos de 100,000 registros calibrados con fuentes clínicas de alto nivel, se implementó un Perceptrón Multicapa (MLP) optimizado con técnicas de regularización y manejo de desbalance de clases. Los resultados muestran una precisión general del 85.45% en el conjunto de prueba, destacando una sensibilidad (Recall) del 85.25% para la detección de casos de riesgo "Severo". El modelo demuestra que las redes neuronales densas son altamente efectivas para identificar patrones complejos en datos tabulares médicos, superando las limitaciones del desbalance estadístico inherente a estos diagnósticos.*

1. INTRODUCCIÓN

En el ámbito de la medicina predictiva, la identificación temprana de riesgos biológicos y conductuales es fundamental para la intervención clínica. Tradicionalmente, los modelos basados en árboles de decisión (GBDTs) han dominado el análisis de datos tabulares; sin embargo, investigaciones recientes sugieren que, con volúmenes de datos significativos, las arquitecturas de *Deep Learning* ofrecen una capacidad de generalización superior.

El presente reporte aborda la problemática de los trastornos del sueño, categorizando el riesgo en cuatro niveles: *Healthy, Mild, Moderate* y *Severe*. Para ello, se emplea un dataset de 100,000 registros sintéticos cuya estructura refleja distribuciones del mundo real. Uno de los retos críticos de este estudio es el marcado desbalance de clases, donde los casos severos representan únicamente el 4.06% de la muestra. La metodología propuesta se enfoca en mitigar este sesgo mediante la integración de pesos de clase en la función de pérdida y el uso de Batch Normalization y Dropout, garantizando que el modelo no sólo sea preciso globalmente, sino también sensible ante los pacientes en situación crítica.

2. DESCRIPCIÓN DEL DATASET

El *dataset* utilizado para este modelo es un archivo cvs que contiene 100,000 registros sintéticos de pacientes para garantizar su privacidad. Sin embargo, sus distribuciones y correlaciones están calibradas con fuentes de investigación clínica de alto nivel, incluyendo la Encuesta Nacional de Entrevistas de Salud del CDC (2024), estudios de la *Sleep Foundation*, *Frontiers in Sleep (2025)* y el *Framingham Heart Study* [1]. Esto asegura que las relaciones estadísticas reflejan patrones del mundo real.

2a.- Estructura de Datos

Para un análisis integral, las variables del estudio se presentaron en seis dimensiones clave: Demográfica (perfil del usuario), Arquitectura del Sueño (métricas físicas del descanso), Estilo de Vida (hábitos y actividad física), Contexto Psicológico (estado mental y niveles de estrés), Factores de Salud (indicadores clínicos) y Factores Ambientales (clima y estacionalidad). Cabe destacar que, aunque el dataset original contaba con 32 columnas, el proceso de preprocesamiento y codificación expandió la cantidad de características a 57 variables, pero optimizó la representación de los datos para el entrenamiento del modelo.

Variable objetivo/dependiente:

Atributo	Descripción	Rango/Ejemplo
sleep_disorder_risk	Multicategoría que clasifica el riesgo de trastornos del sueño	Healthy, Mild, Moderate, Severe

Tabla 1. Descripción y rango de la variable objetivo/dependiente

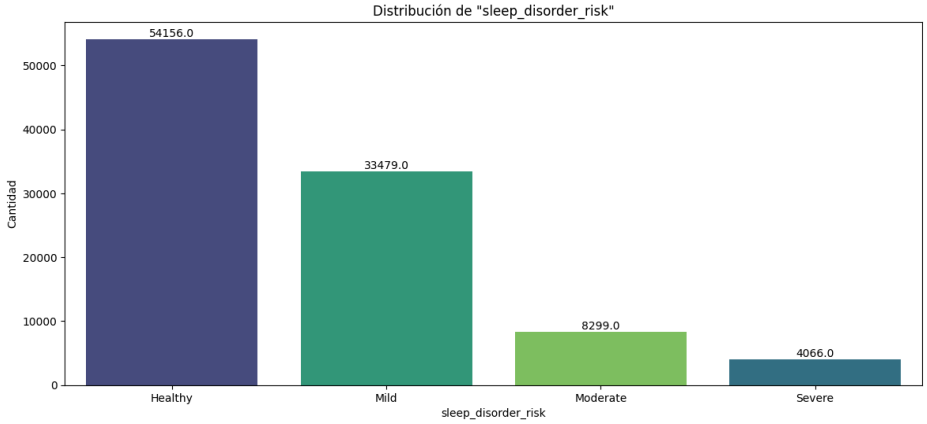

Health	54.16%
Mild	33.48%
Moderate	8.3%
Severe	4.06%

Figura 1. Distribución de la variable objetivo/dependiente.

Contamos con una clase altamente desbalanceada, ya que la variable con mayor cantidad de registros, "Healthy", representa más de la mitad de los datos, mientras que aquella menos presente, "Severe", apenas es el 4% del total de registros.

Variables numéricas:

Atributo	Descripción	Rango/Ejemplo
age	Edad en años	18-69 años
bmi	Índice de Masa Corporal. Medida de la grasa corporal basada en el peso y altura	16-45
sleep_duration_hrs	Duración del sueño en ese día/noche	3-10.5 horas
sleep_quality_score	Clasificación subjetiva de la calidad del sueño	1 = muy mala / 10 = excelente
rem_percentage	Porcentaje de sueño en fase REM	10-30%
deep_sleep_percentage	Porcentaje de sueño en la fase de sueño profundo (ondas lentas)	5-30%
sleep_latency_mins	Tiempo en minutos que se tarda en quedarse dormido, valores >30 indican señal de insomnio	1-58 minutos
wake_episodes_per_night	Cantidad de veces que se despertó durante la noche	0-8 veces
alcohol_units_before_bed	Vasos de alcohol consumidos antes de acostarse	0-6 unidades
screen_time_before_bed_mins	Tiempo de pantalla en minutos antes de acostarse	2-180 minutos
steps_that_day	Total de pasos en el día	500-20,000 pasos
nap_duration_mins	Duración en minutos de las siestas en el día	0-116 minutos
stress_score	Calificación percibida del estrés ese día	1 = muy bajo / 10 =extremo
work_hours_that_day	Horas trabajadas ese día (incluye fines de semana)	0-18 horas
heart_rate_resting_bpm	Frecuencia cardiaca en reposo	45-99 latidos por minuto
room_temperature_celsius	Temperatura del cuarto en grados Celsius. Rango óptimo entre 18-20°C)	15-28°C
weekend_sleep_diff_hrs	Diferencia entre la duración del sueño entre fin de semana y días hábiles(jet lag social)	-1-3 horas
caffeine_mg_before_bed	Cafeína en miligramos consumida mínimo 3 horas antes de acostarse	• 0 • 80 • 150 • 300 • 40 • 100 • 200 • 400

Tabla 2. Atributos, descripción y rangos de las variables numéricas del estudio.

Variables categóricas nominales:

Atributo	Descripción	Rango/Ejemplo
gender	Identidad de género del paciente	Female, Male, Other
occupation	Ocupación del individuo	Student, Software Engineer, Nurse, Manager, Teacher, Doctor, Retired, Sales, Freelancer, Driver, Homemaker, Lawyer
country	País de residencia del paciente (15 categorías)	• USA • Germany • South Korea • India • Canada • Mexico • Japan • France • Netherlands • UK • Australia • Spain • Brazil • Italy • Sweden
chronotype	Preferencia natural del ciclo sueño-vigilia; aquellos tipo vespertino (Evening) suelen tardar más en conciliar el sueño	Neutral (sin preferencia marcada) Morning (duermen y despiertan temprano) Evening (duermen y despiertan tarde)

mental_health_condition	Estado de salud mental existente que afecta los patrones de sueño	Healthy, Anxiety, Depression, Both
season	Estación del año al momento del registro; afecta el ritmo circadiano	Spring, Summer, Autumn, Winter

Tabla 3. Atributos y categorías de las variables categóricas nominales.

Variables categóricas binarias:

Atributo	Descripción
exercise_day	El individuo se ejercitó ese día (1 = sí / 0 = no)
sleep_aid_used	Se utilizó un auxiliar para dormir (melatonina, medicación) esa noche (1 = sí / 0 = no)
shift_work	La persona realiza trabajo por turnos rotativos o nocturnos (1 = sí / 0 = no)
day_type	El registro es de un día hábil "Weekday" o fin de semana "Weekend"

Tabla 4. Descripción de las variables categóricas binarias utilizadas en el modelo.

2b.- División de Dataset en Conjuntos para Entrenamiento, Validación y Prueba

El conjunto de datos se dividió en subconjuntos de entrenamiento(train), validación(validation) y prueba(test) utilizando la función *train_test_split* de la biblioteca *scikit-learn*. Inicialmente, se separó el **70%** de los datos para entrenamiento y el 30% restante se destinó a un conjunto temporal. Posteriormente, este 30% se dividió equitativamente para obtener los conjuntos de validación y prueba (**15%** cada uno del total).

La partición se realizó de forma estratificada con respecto a la variable objetivo, con el fin de preservar la distribución de clases en cada subconjunto. Además, se usó una semilla aleatoria (*random_state*=42) para garantizar la reproducibilidad de resultados.

3. PREPROCESAMIENTO DE DATOS

3a.- Limpieza Inicial

Se eliminó la variable categórica "patient_id", aunque fue de utilidad para validar que no existiera el *id* duplicado de un paciente no aporta información relevante para el modelo de predicción.

También, se eliminaron las variables "cognitive_performance_score" y "felt_rested", ya que, aunque fueron propuestas como variables objetivo en la documentación original del *dataset*, no forman parte del alcance en este estudio.

Asimismo, la variable categórica binaria "day_type" fue transformada en una variable de tipo int mediante una codificación 0/1, asignando el valor de 1 a los días hábiles (Weekday) y 0 a los fines de semana (Weekend), con el fin de facilitar su uso en el modelo.

3b.- Estandarización de variables numéricas

Como parte del preprocesamiento, se aplicó una estandarización tipo z-score a las variables numéricas, transformándolas para tener media cero y desviación estándar uno. Esto permite que las variables sean comparables en escala, evitando que aquellas con mayor magnitud influyan desproporcionadamente en el entrenamiento del modelo. Contribuye a la estabilidad del ajuste.

Para prevenir fuga de información (*data leakage*), los parámetros de estandarización (media y desviación estándar) se calcularon a partir del conjunto de entrenamiento, y posteriormente se aplicaron sin modificación a los conjuntos de validación y prueba. Este procedimiento se implementó utilizando la clase *StandardScaler* de la biblioteca *scikit-learn*, ajustando el modelo sólo con los datos de entrenamiento y reutilizando dichos parámetros en los demás conjuntos.

3c.- Codificación de variables categóricas

Se aplicó codificación *One-Hot Encoding* a las variables categóricas nominales, aquellas sin orden inherente entre categorías. Esta técnica transforma cada categoría en una variable binaria, tomando el valor de 1 cuando el registro pertenece a dicha categoría y 0 en caso contrario. Este enfoque evita introducir relaciones ordinales irreales que podrían surgir al codificar las categorías con números enteros.

Para prevenir problemas de multicolinealidad, se utilizó una codificación de n-1 categorías, omitiendo una como referencia. Esto elimina la dependencia lineal entre las variables generadas (que su suma sea 1), y así el modelo estima los efectos de cada categoría en relación con la categoría base.

Se aplicó una codificación *Label Encoder* a la variable objetivo, transformando las 4 clases a valores numéricos enteros.

3d.- Consideraciones Adicionales

El dataset original contaba con 32 columnas. Tras el proceso de limpieza y transformación, la estructura final se ajustó de la siguiente manera.

Estado del *dataset*	**Número de columnas**	**Acción**
Original	32	Carga inicial del CSV.
Post-Limpieza	29	Eliminación de IDs y targets secundarios.
Preprocesamiento Final	58	Aplicación de estandarización y codificación.

Tabla 5. Transformación de la estructura del dataset y evolución del número de columnas durante el preprocesamiento.

4. MODELO BASE

4a.- Construcción del modelo

Durante años, se trabajó con la premisa de que los modelos basados en árboles, como los Gradient Boosted Decision Trees (GBDTs), son superiores para datos tabulares debido a su robustez y escalabilidad. Sin embargo, estudios de benchmarking realizados sobre más de conjuntos de datos diversos indican que, bajo protocolos de optimización adecuados y cuando se dispone de un volumen de datos significativo, los modelos de aprendizaje profundo (Deep Learning) logran superar de consistentemente los enfoques clásicos de GBDT. [2]

En el contexto específico de la clasificación de trastornos del sueño, el estudio "Applying Machine Learning Algorithms for the Classification of Sleep Disorders" realizó una comparación directa entre algoritmos convencionales y redes neuronales artificiales (ANN) utilizando el "Sleep Health and Lifestyle Dataset". Los resultados de dicha investigación demostraron que la ANN alcanzó la precisión más alta con un 92.92%, superando notablemente a otros modelos de alta capacidad. [4]

Es por esto que para abordar este reto de clasificación múltiple se desarrolló un Perceptrón Multicapa (MLP) con capas densas. La estructura del modelo base se detalla a continuación:

Capa (Tipo)	**Configuración**	**Justificación**
Entrada	57 features	Corresponde a las variables tras la codificación One-Hot y estandarización Z-score.
Densa 1	128 neuronas, activación ReLU	Capacidad suficiente para extracción inicial de patrones con alta dimensionalidad.
Regularización	Batch Normalization	Estabiliza el aprendizaje y acelera la convergencia al normalizar las activaciones de la capa anterior.
Dropout	Tasa de 0.3	Evitar el sobreajuste y promover la generalización al desactivar el 30% de las conexiones.
Densa_1	64 neuronas, activación ReLU	Refinamiento de los parámetros.
Dropout_1	Tasa de 0.2	Evitar el sobreajuste.
Densa_2	4 neuronas, activación Softmax	Genera la distribución de probabilidad de las 4 categorías de riesgo.

Tabla 6. Configuración y justificación técnica de la arquitectura del Perceptrón Multicapa (MLP)

TensorFlow, a través de su API Keras, ofrece las herramientas necesarias para construir esta red de forma modular y eficiente.

La elección de la función de activación ReLU es fundamental. A diferencia de las funciones sigmoideas, ReLU no satura en el rango positivo, así permite un entrenamiento más rápido y eficiente en redes profundas. Sin embargo, se ha complementado con técnicas de regularización avanzadas para garantizar que el modelo no simplemente memorice el ruido inherente de los datos sintéticos de 100,000 registros, sino que aprenda estructuras relevantes. [3]

El optimizador seleccionado es Adam con el *Learning Rate* por defecto de 0.001. Este es robusto para datos tabulares y maneja eficientemente gradientes dispersos, lo cual es común cuando hay muchas variables binarias resultantes del One-Hot Encoding. [2]

Además, en el entrenamiento se implementó *Early Stopping*, no se limita a un número fijo de épocas, sino que es monitoreado dinámicamente. Al supervisar la pérdida en el conjunto de validación, el entrenamiento se detiene en el momento en que la red comienza a especializarse excesivamente en los datos de entrenamiento (memorización). Este procedimiento restaura automáticamente los pesos del modelo al punto de su mejor desempeño validado.

4b.- Manejo de desbalance de clases

Uno de los mayores desafíos con este *dataset* es la distribución desigual de las clases. En entornos clínicos, los individuos sanos suelen superar en número a aquellos con riesgos moderados o severos. El desbalance de clases inclina el sesgo hacia la clase mayoritaria, lo que resulta en una alta precisión global pero una sensibilidad nula para los casos de alto riesgo, los cuales son precisamente los de mayor interés.

Para corregir esta tendencia hacia la clase mayoritaria, se empleó la función *compute_class_weight* de *scikit-learn* con el argumento “balanced”. Esta técnica calcula pesos específicos para cada categoría según la fórmula:

$$Wj = \frac{no.samples}{no.clases * no.samples_j}$$

Estos pesos se integran en el entrenamiento para ajustar la función de pérdida; de este modo, el error cometido en una predicción de la clase "Severe" se penaliza con mayor severidad que un error en la clase "Healthy". Esta justificación matemática permite que el modelo asigne una importancia proporcionalmente mayor a los pacientes en alto riesgo.

5. EVALUACIÓN DE RESULTADOS

5a. Marco teórico de las Métricas de Evaluación

En la evaluación de modelos diagnósticos, la exactitud global (*Accuracy*) es a menudo una métrica insuficiente y potencialmente engañosa, especialmente cuando existe un desbalance de clases significativo. Para una interpretación pertinente de la capacidad predictiva es necesario emplear métricas derivadas de la matriz de confusión que permitan cuantificar de manera independiente el rendimiento sobre cada nivel de riesgo [2]. Estas métricas se definen formalmente a continuación utilizando la notación estándar de Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN).

A. Precisión (Precision). Mide la capacidad del modelo para no etiquetar como positiva una muestra que es negativa. Representando la probabilidad de que un paciente realmente tenga un trastorno del sueño dado que el modelo ha emitido un diagnóstico positivo. Una baja precisión resultaría en un exceso de "falsas alarmas".

B. Exhaustividad o Sensibilidad (Recall). Mide la capacidad del modelo para encontrar todas las muestras positivas. En el contexto del riesgo “Severo” de trastornos del sueño, que esta métrica sea baja significa que pacientes con condiciones potencialmente peligrosas están siendo clasificados erróneamente como “Sanos” o con riesgo “Leve”.

C. F1-Score. Esta es la media armónica de las métricas anteriores. Proporciona una medida del equilibrio entre ambas, penalizando los casos donde una de las dos métricas es excesivamente baja. Es la métrica de referencia en estudios de aprendizaje automático sobre datos tabulares médicos porque ofrece una visión realista del rendimiento del modelo en clases minoritarias pero críticas.

5b.- Análisis de Estabilidad y Convergencia

Los resultados obtenidos tras el entrenamiento demuestran una convergencia estable y un comportamiento de generalización robusto.

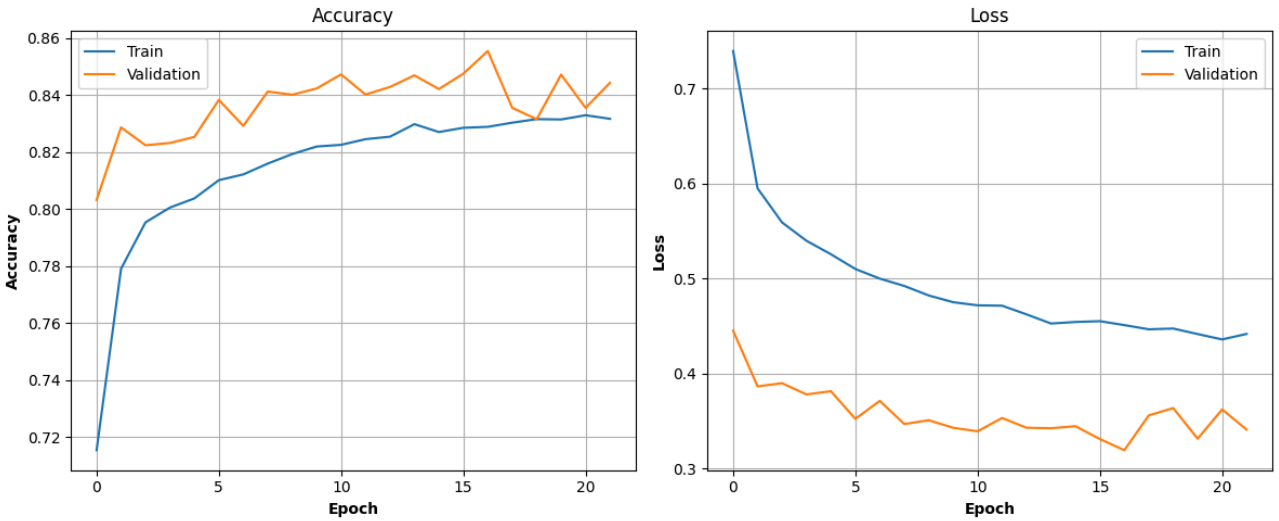

Figura 2. Curvas de convergencia de Accuracy y Loss durante las épocas de entrenamiento y validación.

La similitud del desempeño en el conjunto de prueba es idéntico al de validación (85.45% vs 85.54%), confirmando que el modelo no ha sufrido de sobreajuste (*overfitting*). La ligera mejora del desempeño en validación y prueba respecto al entrenamiento sugiere que el modelo ha logrado aprender patrones generalizables y que las capas de Dropout han cumplido su función de evitar la memorización de casos específicos del *set* de entrenamiento.

Conjunto	Accuracy (modelo final)	Loss (modelo final)
Train	82.88%	0.4509
Validation	85.54%	0.3191
Test	85.45%	0.316

Tabla 7. Desempeño final de Accuracy y Loss en los conjuntos.

Este nivel de estabilidad es consistente con los hallazgos de investigaciones recientes que sugieren que los MLPs, cuando se entrenan con un número suficiente de muestras (N > 50,000), desarrollan una capacidad de representación que iguala o supera a los modelos de GBDT en tareas de clasificación multiclase. Además, el valor de pérdida (Loss) de 0.3160 en el conjunto de prueba indica una confianza alta en las probabilidades asignadas por la capa Softmax, facilitando la toma de decisiones clínicas basadas en umbrales de probabilidad.

4b.- Desempeño por Clase

Como se menciona, el mayor desafío del proyecto radica en la distribución desigual de la variable objetivo, donde la clase "Healthy" representa el 54.16% de los datos y la clase "Severe" solo el 4.06%. El análisis multidimensional por clase revela cómo el modelo ha manejado este desbalance.

Métricas de evaluación	Health	Mild	Moderate	Severe
Precision	93.22%	86.13%	53.03%	71.63%
Recall	94.08%	74.21%	74.52%	85.25%
F1-Score	93.65%	79.73%	61.97%	77.84%
Accuracy general	93.09%	87.37%	92.41%	98.03%

Tabla 8. Métricas de evaluación detalladas (Precisión, Exhaustividad, F1-Score y Accuracy) por clase de riesgo.

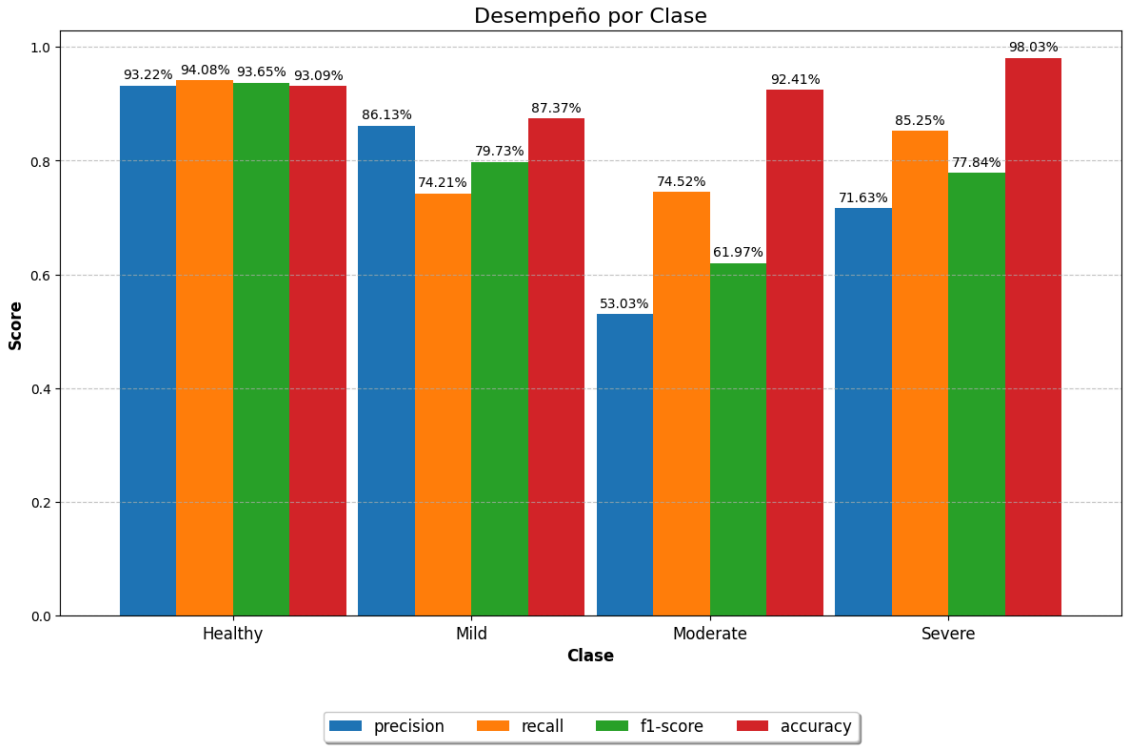

Figura 3. Gráfica comparativa del desempeño por clase según las métricas de evaluación.

El manejo del desbalance se considera exitoso ya que el modelo no ha caído en la trampa de clasificar todo como "Healthy" para maximizar el Accuracy. Como se esperaba, el rendimiento en la clase "Healthy" es el mejor, con un *F1-score* del 93.65%, minimizando falsos diagnósticos en individuos sanos. Sin embargo, desde el punto de vista de la seguridad del paciente, el hallazgo más significativo es el *Recall* del 85.25% para la clase "Severe". Esto indica que el modelo logró aprender las características distintivas de esta población minoritaria y es capaz de identificar correctamente a la gran mayoría de los pacientes con un riesgo crítico de trastorno del sueño, fallando sólo en un 14.75% de los casos graves.

La clase "Moderate" muestra una precisión inferior (53.03%), sugiriendo un fenómeno de superposición diagnóstica. Esto quiere decir que, en la práctica clínica, los síntomas y medidas de riesgo moderado suelen confundirse con los de riesgo leve o incluso con casos saludables bajo ciertas condiciones. A pesar de esta confusión en la precisión, el Recall de 74.52% para esta categoría asegura que tres de cada cuatro pacientes en riesgo moderado sean capturados por el sistema permitiendo una evaluación médica posterior.

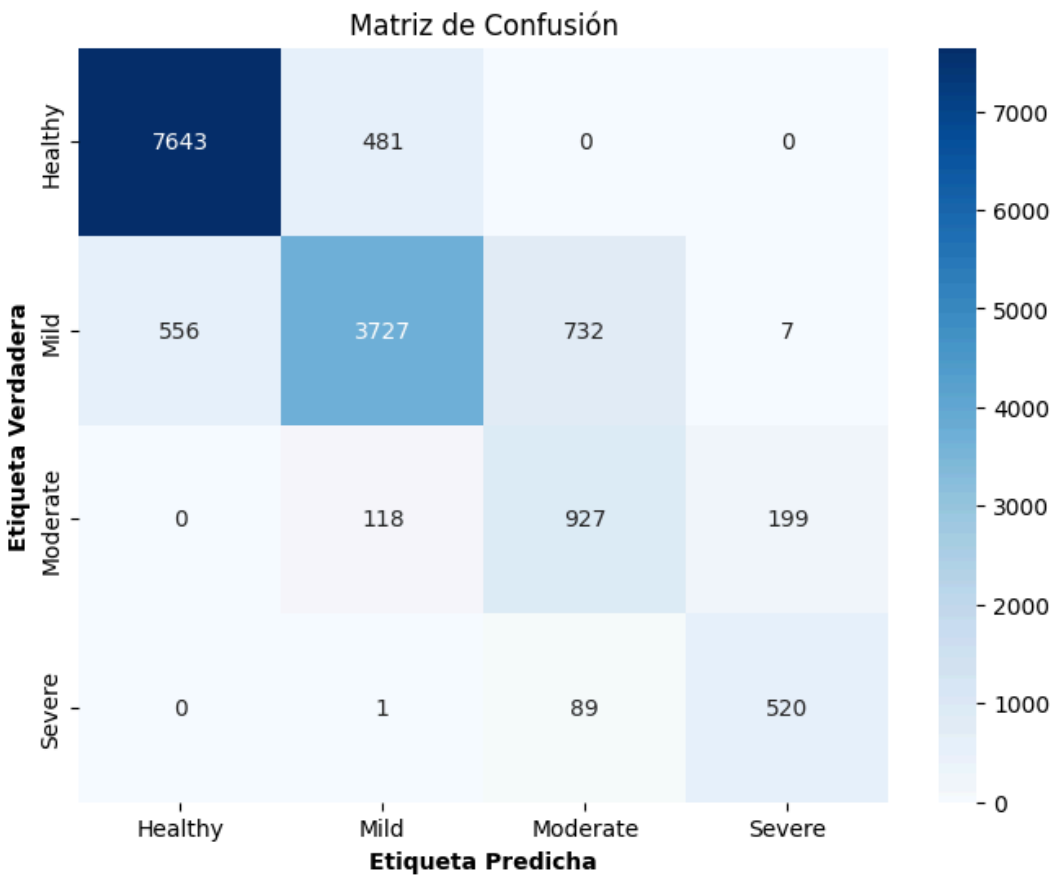

Figura 4. Matriz de confusión para la clasificación multiclase de los niveles de riesgo de trastornos del sueño.

6. REFERENCIAS

[1] Krishna, M.(2026, 12 abril). *Sleep Health & Daily Performance Dataset*. Kaggle. https://www.kaggle.com/datasets/mohankrishnathalla/sleep-health-and-daily-performance-dataset/data

[2] Ye, H., Liu, S., Cai, H., Zhou, Q., & Zhan, D. (2024, 01 julio). *A closer look at deep learning methods on tabular datasets.* arXiv.org. https://arxiv.org/abs/2407.00956

[3] Zabërgja, G., Kadra, A., Frey, C. M. M., & Grabocka, J. (2024, 06 febrero). *Tabular Data: Is Deep Learning all you need?* arXiv.org. https://arxiv.org/abs/2402.03970

[4] Alshammaria, T. (2024, 07 marzo). *Applying machine learning algorithms for the classification of sleep disorders.* IEEE Journals & Magazine | IEEE Xplore. https://ieeexplore.ieee.org/abstract/document/10462120